

**Modelo de clasificación de tumores cerebrales en imágenes de resonancias magnéticas usando  
embedding cuántico y redes neuronales  
Trabajo Terminal No. 2026-A187**

**Alumnos:** Castillo Reyes Diego, \*Muñoz González Eduardo, Yañez Martínez Marthon Leobardo.

**Directores:** Guerrero Estrada Areli Yesareth, Sánchez Manilla Angeles Alejandra

**Correo de contacto:** emunozg1901@alumno.ipn.mx

**Resumen** - La computación cuántica es una tecnología en auge que utiliza las propiedades de la mecánica cuántica de modo que permite reducir la complejidad en operaciones costosas computacionalmente gracias al paralelismo cuántico. En este proyecto se busca optimizar la clasificación de tumores cerebrales en imágenes médicas mediante un enfoque híbrido cuántico-clásico. Utilizaremos *Quantum Feature Embedding*, específicamente *Amplitude Encoding* para extraer representaciones eficientes de imágenes de resonancia magnética (MRI por sus siglas en inglés) y una red neuronal clásica para dar interpretación al resultado de dichos embeddings y realizar la clasificación, esto usando el conjunto de datos proporcionado por Muhammad Al-Zafar Khan et al. [1] con poco más de 3000 MRI, clasificadas entre meningioma, glioma y tumor pituitario.

**Palabras clave** - Circuitos Cuánticos Variacionales, Codificación por Amplitud, Imágenes de Resonancia Magnética, Redes Neuronales Convolucionales, Tumores Cerebrales.

## 1. Introducción

Detectar y diagnosticar tumores cerebrales usando resonancia magnética es clave en medicina. Si el diagnóstico se hace a tiempo y con precisión, el paciente tiene más posibilidades de recibir un tratamiento eficaz y mejorar su pronóstico [2]. En los últimos años, la inteligencia artificial ha cambiado la forma en que se interpretan estas imágenes. Ahora se necesita menos intervención humana y se obtienen diagnósticos más precisos [3]. De hecho, los modelos de aprendizaje profundo han logrado detectar tumores en imágenes médicas con una precisión similar a la de los radiólogos expertos [4].

Entre los desarrollos más avanzados se encuentran BrainTumorSegNet, que emplea redes neuronales convolucionales para segmentación precisa de tumores en imágenes de resonancia magnética [5], y Qure.ai's qER, un software basado en técnicas avanzadas de inteligencia artificial para la detección automática de anomalías cerebrales en imágenes de tomografía computarizada y resonancia magnética [6]. A pesar de su éxito, estos modelos dependen de grandes volúmenes de datos y requieren una alta capacidad de cómputo, lo que limita su aplicabilidad en entornos con recursos computacionales restringidos. Además, la dependencia de técnicas clásicas de aprendizaje automático implica la necesidad de un entrenamiento extenso y la optimización de hiperparámetros, lo que puede ralentizar su implementación en entornos clínicos reales.

En este contexto, la computación cuántica ha emergido como una alternativa revolucionaria, capaz de superar algunas de las limitaciones de los enfoques tradicionales. Basada en principios de la mecánica cuántica, como la superposición y el entrelazamiento, la computación cuántica ofrece nuevas formas de representar y procesar información, aumentando la eficiencia computacional y reduciendo el tiempo necesario para realizar tareas de clasificación de imágenes. La superposición permite a los qubits representar simultáneamente múltiples estados de información, mientras que el entrelazamiento proporciona correlaciones instantáneas entre qubits, mejorando la capacidad de procesamiento.

A diferencia de los bits tradicionales, que solo pueden adoptar valores de 0 o 1, los qubits pueden existir en

una superposición de ambos estados simultáneamente. Esta propiedad permite que el poder computacional de un sistema cuántico crezca en un factor de  $2^n$ , donde n representa el número de qubits utilizados. Como resultado, los algoritmos cuánticos pueden abordar problemas de alta complejidad con una cantidad reducida de recursos computacionales en comparación con sus contrapartes clásicas. Además, las técnicas cuánticas pueden facilitar la reducción de dimensionalidad en datos médicos, permitiendo que los modelos trabajen con conjuntos de características más manejables sin perder información clave para la clasificación. [7]

La hipótesis que planteamos es que al desarrollar una arquitectura de red híbrida utilizando un algoritmo cuántico de extracción de características conocido como **Amplitude Encoding** (Codificación por Amplitud) [8] junto con una red neuronal clásica, obtendremos un modelo con mejor desempeño en comparación con otro enfoque híbrido de clasificación, como el establecido por Khan et al. [1], el cuál hace uso de la codificación angular en el preprocesamiento para su posterior en la clasificación de MRI cuyo porcentaje de precisión era de aproximadamente 91.4 %.

Modelos similares que se han desarrollado son:

1. **HQC-CNN**: Red Convolutiva Híbrida Cuántico-Clásica para Tumores Cerebrales [9].
2. **Transfer Learning Cuántico**: AlexNet + Circuito Cuántico para Alzheimer y Parkinson [10].
3. **HQCNN**: Red Cuántico-Clásica con Embedding Angular para Clasificación de Tumores Cerebrales [11].

Modelo	Enfoque técnico	Aplicación clínica
HQC-CNN	Red híbrida cuántico-clásica; circuito cuántico parametrizado para extracción de características.	Clasificación de tumores cerebrales en imágenes de resonancia magnética (MRI).
Transfer Learning Cuántico	Modelo basado en AlexNet con circuito cuántico variacional.	Diagnóstico de Alzheimer y Parkinson a partir de MRI.
Hybrid Quantum Convolutional Neural Networks (HQCNN)	Red convolutiva híbrida que combina embedding cuántico angular con capas convolucionales clásicas.	Clasificación de tumores cerebrales en imágenes de resonancia magnética (MRI), específicamente para glioma, meningioma y adenoma pituitario.
Solución propuesta	Quantum Feature Embedding + red neuronal clásica para interpretación y clasificación.	Clasificación binaria de imágenes de resonancia magnética cerebral para detectar la presencia o ausencia de tumores.

Cuadro 1: Resumen de modelos similares.

## 2. Objetivo

Objetivo general: Desarrollar un modelo híbrido cuántico-clásico basado en codificación por amplitud para la clasificación de tumores en imágenes de resonancia magnética, optimizando la extracción de características.

Objetivos específicos:

- Analizar los algoritmos de redes neuronales del estado del arte que se emplean para procesamiento de imágenes.
- Analizar el preprocesamiento de imágenes que presente mejores resultados con el algoritmo seleccionado.
- Implementar un circuito cuántico variacional de codificación por amplitud para la extracción de características en imágenes de resonancia magnética.
- Entrenar el modelo híbrido en un entorno de simulación cuántica, optimizando su arquitectura para mejorar la clasificación de tumores.
- Comparar el rendimiento del modelo propuesto con el modelo usado por Khan et al. [11].

## 3. Justificación

El cáncer, también conocido como neoplasia maligna o tumor maligno, es una enfermedad que se caracteriza por la multiplicación descontrolada de células anormales que pueden invadir tejidos y órganos del cuerpo. De acuerdo con el INEGI, en México durante 2023 se registraron 91,562 muertes por tumores malignos, lo que representa un 11.4% del total de defunciones en el país [11]. Sin embargo las estadísticas generales no desglosan específicamente los casos con tumores cerebrales, es evidente que contribuyen una causa de mortalidad. Por ello el diagnóstico preciso y oportuno de tumores cerebrales a partir de imágenes de resonancia magnética (IRM) es crítico para la toma de decisiones médicas. No obstante, los modelos tradicionales de clasificación de imágenes basados en aprendizaje profundo requieren grandes volúmenes de datos, alto poder de cómputo y tiempo de entrenamiento prolongados, lo que limita su escalabilidad en entornos clínicos reales.

Por su parte, los métodos actuales de clasificación cuántica pueden no ser lo suficientemente eficientes en la extracción de características relevantes, lo que afecta la precisión y confiabilidad del diagnóstico. Este proyecto propone una solución innovadora mediante la integración de Quantum Feature Embedding, específicamente la codificación por amplitud en un modelo híbrido cuántico-clásico, con el objetivo de mejorar la extracción de características en imágenes médicas y optimizar la clasificación de tumores. Esta aproximación permitiría un procesamiento más eficiente de los datos con una menor cantidad de parámetros, lo que reduciría la carga computacional sin comprometer la precisión del diagnóstico. Cabe destacar que la investigación no partirá de una exploración abierta, sino que seguirá una metodología bien definida y con sustento en evidencia previa.

Dentro de sus contribuciones principales se destaca por su originalidad, ya que se hará una exploración sistemática y comparativa entre las aplicaciones de computación cuántica en la detección de tumores, un área emergente con gran potencial en la medicina, así como su utilidad en el resultado final, de modo que, un modelo más eficiente y preciso beneficiaría a radiólogos y especialistas médicos en la detección temprana de tumores cerebrales.

Nuestro trabajo se alinea con las tendencias actuales en el uso de tecnologías híbridas en imágenes biomédicas, y podría establecer bases sólidas para futuras aplicaciones en otros dominios clínicos. Artículos recientes de IBM, Khan y Maouaki [12], [1], [13] refuerzan la viabilidad de este enfoque y sirven como guía para la validación de nuestra propuesta. Específicamente, el conjunto de datos que se utilizará en este proyecto [14] ya ha sido empleado para la clasificación cuántica de imágenes, como se demuestra en el trabajo de Al-Dharrab et al [1]. Esta referencia no solo valida la idoneidad del conjunto de datos, sino que también nos da una referencia directa y un *benchmark* para nuestra metodología y resultados, permitiéndonos construir sobre una base metodológica probada.

#### 4. Resultado Esperado

Nuestro diagrama representado en la imagen 1 representa una idea general del modelo híbrido cuántico-clásico diseñado para la clasificación de imágenes de resonancia magnética con el objetivo de detectar tumores. El proceso comienza con la entrada de imágenes clásicas que fueron conseguidas por medio de un Dataset público [14].

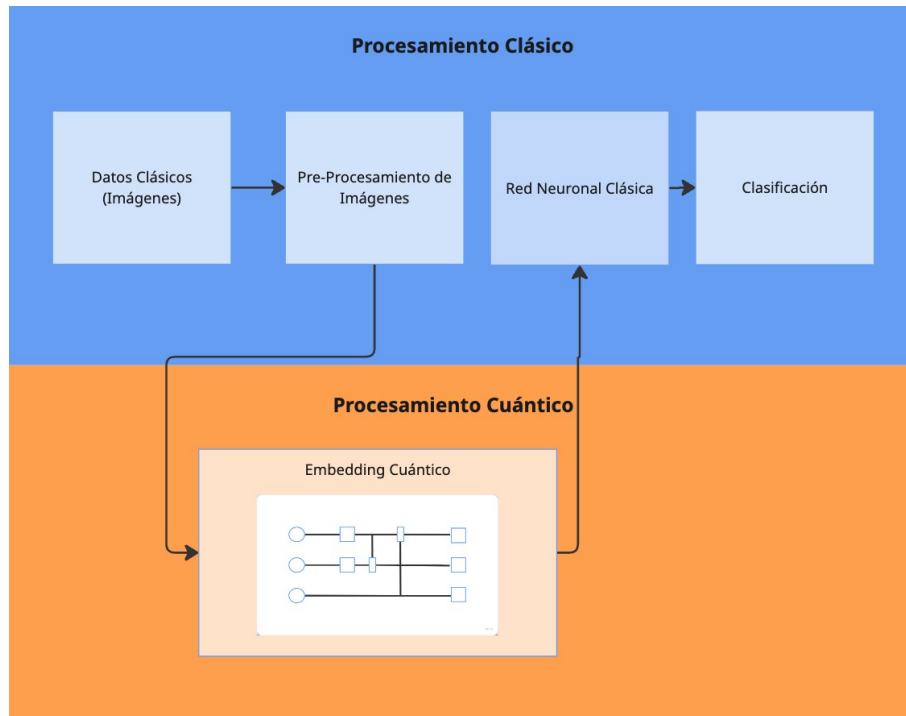


Figura 1: Arquitectura del programa

El Dataset está compuesto por 3064 imágenes de alto contraste de 233 pacientes con tres tipos de tumores: Meningioma, Glioma y Adenoma hipofisario. Cada imagen está en un formato de Matlab (.mat), cuya información contiene:

- Datos de imagen.
- Etiqueta de tumor (Meningioma, Glioma, Adenoma hipofisario).
- ID del paciente.

- Coordenadas de los bordes del tumor.
- Mascara del tumor.

Para este proyecto, el enfoque se centrará en un problema de clasificación binaria, utilizando solo dos de los tres tipos de tumores disponibles para diferenciar entre ellos:

- Glioma.
- Adenoma hipofisiario.

Las imágenes pasarán a ser cargadas en Python para seguir el embedding. El embedding es un proceso en donde los datos clásicos son transformados a estados cuánticos por medio de un mapa cuántico, el cual es una función matemática que traduce datos clásicos a un espacio de Hilbert [15]. Nuestro embedding, en particular, consiste en mapear la información de las imágenes a un espacio de estados cuánticos mediante diferentes estrategias, como el codificado por ángulos o por amplitudes. Un ejemplo de cómo se realiza la codificación es representado por la imagen 2. El objetivo de esta fase es aprovechar la capacidad de representación del cómputo cuántico para obtener un vector de características que describa la imagen en un espacio de alta dimensión.




Figura 2: Datos clásicos mapeados a un espacio Hilbert

El vector de características resultante es luego procesado por una red neuronal clásica, que aprende a reconocer patrones en los datos cuánticos y a clasificarlos según la presencia o ausencia de un tumor en la imagen. Esta red puede estar compuesta por capas densas o convolucionales, dependiendo del enfoque adoptado. Para evaluar el rendimiento del modelo de clasificación se mostrará una matriz de confusión.

Se esperan los siguientes productos:

- Algoritmo de clasificación
- Documentación del modelo
- Reporte de resultados

## 5. Metodología

La metodología está fundamentada en los principios de mejora continua definidos por la norma ISO 9001:2015, donde se buscará garantizar la calidad en cada etapa de desarrollo del modelo mediante ciclos iterativos de desarrollo, evaluación y optimización.

El desarrollo del proyecto se realizará utilizando tres computadoras: una Lenovo Legión 5 con procesador Intel Core i7 de décima generación, tarjeta gráfica NVIDIA RTX 2060 de 6GB VRAM y 32GB de RAM,

una ASUS ROG equipada con procesador AMD Ryzen 7 6800H, tarjeta gráfica NVIDIA RTX 3050 de 4GB VRAM y 16GB de RAM y una Mac de escritorio con el procesador M1. Estos equipos ofrecerán la capacidad de procesamiento necesaria para realizar simulaciones cuánticas y entrenamiento de modelos de aprendizaje profundo.

En cuanto a las herramientas virtuales de desarrollo se utilizará Python como lenguaje principal para el desarrollo del modelo. También, se emplearán las siguientes bibliotecas y dependencias:

- **NumPy o TensorFlow:** Para construir y entrenar la parte clásica de la red. PennyLane se integra de forma nativa con ambos.
- **Pandas:** Para poder guardar los resultados en un CSV.
- **Matplotlib:** Para visualizar los resultados de los productos.
- **OpenCV:** Para normalizar las imágenes.
- **h5py:** Para cargar y organizar las imágenes de tipo .mat a Python.
- **Scikit-learn:** Para el cálculo de métricas de rendimiento detalladas (matriz de confusión, reporte de clasificación).
- **PennyLane:** Para definir y ejecutar los circuitos cuánticos y calcular sus gradientes.

Git y GitHub, para el control de versiones del código y la gestión colaborativa del proyecto; LaTeX y Jupyter Notebook, para realizar la documentación y análisis de resultados, facilitando su presentación clara y precisa del desarrollo y los hallazgos del proyecto.

El proceso comienza con la carga de conjunto de datos público previamente mencionado [14] que contiene 3064 imágenes de resonancia magnética de 233 pacientes. Para este proyecto, el enfoque se centrará en un problema de clasificación binaria, utilizando solo dos de los tres tipos de tumores disponibles: Glioma (1426 imágenes) y Adenoma hipofisario (930 imágenes).

Antes del mapeo cuántico, las imágenes se preprocesarán de la siguiente manera:

1. Se cargarán los archivos .mat usando h5py para extraer la imagen y la máscara del tumor.
2. Utilizando la máscara, se segmentará la región de interés para enfocar el análisis.
3. Las imágenes serán sometidas a un redimensionamiento a un tamaño manejable (e.g., 32×32 píxeles) para adecuarlas a la capacidad de los simuladores cuánticos.
4. Los valores de los píxeles se normalizarán al rango [0,1] para facilitar su codificación.

Los datos preprocesados se dividirán en tres subconjuntos utilizando una semilla aleatoria fija para garantizar la reproducibilidad:

- **70 % o 80 % para entrenamiento:** Usado para ajustar los parámetros del modelo.
- **15 % o 10 % para validación:** Empleado para la optimización de hiperparámetros y evitar el sobreajuste.
- **15 % o 10 % para prueba:** Reservado para la evaluación final del rendimiento del modelo.

El núcleo de la metodología es un modelo híbrido. Se inicializará un dispositivo cuántico con 4 qubits para un filtro de 2x2. Las imágenes preprocesadas pasarán a la etapa de embedding, donde los datos clásicos se transforman a estados cuánticos mediante un mapa cuántico por amplitudes. El vector de características cuánticas resultante será procesado por una red neuronal clásica que realizará la clasificación final. Esperamos que nuestro proyecto llegue a una precisión de validación/prueba con un rendimiento robusto con precisión del 91.47 % como en el artículo en el cual nos estamos basando [1].

Durante el desarrollo se aplicará un enfoque iterativo de mejora, evaluando constantemente el desempeño del modelo mediante métricas específicas de precisión, sensibilidad y eficiencia computacional. Cada iteración será documentada y evaluada para identificar oportunidades de mejora, permitiendo ajustar el diseño del modelo híbrido hasta alcanzar resultados óptimos para la clasificación.

## 6. Cronogramas

Alumno: Diego Castillo Reyes	2025					2026					
Actividad	AGO	SEP	OCT	NOV	DIC	ENE	FEB	MAR	ABR	MAY	JUN
Planificación del sistema de calidad y definición del proceso de embedding cuántico											
Estandarización del preprocesamiento conforme a criterios de calidad (ruido, segmentación, normalización)											
Desarrollo inicial del Quantum Feature Embedding en PennyLane											
Implementación de codificación cuántica de imágenes médicas (amplitude encoding)											
Optimización técnica del embedding conforme a criterios de desempeño											
Verificación de conformidad del embedding cuántico con criterios clínicos y computacionales											
Generación de salida interpretable para redes neuronales clásicas											
Integración del módulo cuántico con la red neuronal para clasificación final											
Evaluación funcional del sistema híbrido y comparación con métodos clásicos											
Análisis estadístico de precisión y sensibilidad de la clasificación binaria											
Evaluación de costo computacional, viabilidad y escalabilidad del sistema											
Artículo técnico de TT											
Reporte técnico de TT											
Revisión y mejora del sistema de clasificación conforme al ciclo PDCA											

Figura 3: Cronograma de actividades para Diego Castillo Reyes

Alumno: Eduardo Muñoz González	2025					2026					
<b>Actividad</b>	AGO	SEP	OCT	NOV	DIC	ENE	FEB	MAR	ABR	MAY	JUN
Planificación de la integración de calidad del sistema híbrido											
Investigación sobre arquitecturas eficientes de redes neuronales clásicas											
Desarrollo de red neuronal base en TensorFlow/PyTorch											
Ajuste de arquitectura para acoplamiento con embeddings cuánticos											
Entrenamiento y pruebas iniciales del modelo híbrido											
Comparación controlada con modelos sin embeddings cuánticos											
Integración final del sistema híbrido optimizado											
Verificación funcional conforme a requisitos computacionales y clínicos											
Comparación objetiva con otros enfoques clásicos y cuánticos											
Análisis de desempeño y generalización en clasificación médica											
Evaluación del costo computacional y recursos del sistema híbrido											
Artículo técnico de TT											
Reporte técnico de TT											
Revisión y mejora del sistema híbrido bajo el ciclo PDCA											

Figura 4: Cronograma de actividades para Eduardo Muñoz González



Alumno: Marthon Leobardo Yañez Martínez	2025					2026					
<b>Actividad</b>	AGO	SEP	OCT	NOV	DIC	ENE	FEB	MAR	ABR	MAY	JUN
Revisión de literatura sobre validación de modelos híbridos conforme a calidad											
Definición de indicadores de calidad y precisión del modelo											
Estandarización del preprocesamiento de imágenes (ruido, segmentación, normalización)											
Desarrollo técnico del embedding cuántico y simulaciones											
Análisis funcional de los resultados de embeddings											
Implementación de métricas de evaluación ISO											
Evaluación de la integración embedding + red neuronal											
Evaluación en múltiples conjuntos de datos clínicos											
Análisis estadístico conforme a criterios de calidad											
Artículo técnico de TT											
Reporte técnico de TT											
Revisión final y mejora continua bajo ciclo PDCA											

Figura 5: Cronograma de actividades para Marthon Leobardo Yañez Martinez

## Referencias

- [1] M. A.-Z. Khan, N. Innan, A. A. O. Galib, and M. Bennai, “Brain tumor diagnosis using hybrid quantum convolutional neural networks,” *arXiv preprint arXiv:2401.15804*, 2024. [Online]. Available: <https://arxiv.org/pdf/2401.15804>
- [2] Z. Akkus, A. Galimzianova, A. Hoogi, D. L. Rubin, and B. J. Erickson, “Deep learning for brain mri segmentation: State of the art and future directions,” *Journal of Digital Imaging*, vol. 30, no. 4, pp. 449–459, 2017. [Online]. Available: <https://doi.org/10.1007/s10278-017-9983-4>
- [3] C. J. Liew, “The role of artificial intelligence in diagnostic radiology: a survey at a single academic institution,” *Journal of the American College of Radiology*, vol. 15, no. 3, pp. 512–517, 2018.
- [4] S. Pereira, A. Pinto, V. Alves, and C. A. Silva, “Brain tumor segmentation using convolutional neural networks in mri images,” *IEEE Transactions on Medical Imaging*, vol. 35, no. 5, pp. 1240–1251, May 2016. [Online]. Available: <https://doi.org/10.1109/TMI.2016.2538465>
- [5] X. Hu, W. Luo, J. Hu, S. Guo, W. Huang, M. R. Scott, R. Wiest, M. Dahlweid, and M. Reyes, “Brain segnet: 3d local refinement network for brain lesion segmentation,” *BMC Medical Imaging*, Tech. Rep. 10.1186, 2020, Último acceso: 1 de marzo de 2025. [Online]. Available: <https://bmcmmedimaging.biomedcentral.com/articles/10.1186/s12880-020-0409-2>
- [6] Quare.ai, “Qure.ai’s qer: The globally proven algorithm for head cts,” 2024, Último acceso: 1 de marzo de 2025. [Online]. Available: [https://www.qure.ai/impact\\_stories/qure.ai-qER-the-globally-proven-algorithm-for-head-cts](https://www.qure.ai/impact_stories/qure.ai-qER-the-globally-proven-algorithm-for-head-cts)
- [7] D. McMahon, *Quantum Computing Explained*. Wiley-IEEE Computer Society Press, 2007. [Online]. Available: <https://www.wiley.com/en-us/Quantum+Computing+Explained-p-9780470096994>
- [8] K. Nakaji, S. Uno, Y. Suzuki, R. Raymond, T. Onodera, T. Tanaka, H. Tezuka, N. Mitsuda, and N. Yamamoto, “Approximate amplitude encoding in shallow parameterized quantum circuits and its application to financial market indicators,” *Physical Review Research*, vol. 4, no. 2, p. 023136, 2022.
- [9] Y. Dong, Y. Fu, H. Liu, X. Che, L. Sun, and Y. Luo, “An improved hybrid quantum-classical convolutional neural network for multi-class brain tumor mri classification,” *Journal of Applied Physics*, vol. 133, no. 6, p. 064401, 02 2023. [Online]. Available: <https://doi.org/10.1063/5.0138021>
- [10] N. Alsharabi, T. Shahwar, A. U. Rehman, and Y. Alharbi, “Implementing magnetic resonance imaging brain disorder classification via alexnet–quantum learning,” *Mathematics*, vol. 11, no. 2, 2023. [Online]. Available: <https://www.mdpi.com/2227-7390/11/2/376>
- [11] I. N. de Estadística y Geografía (INEGI), “Estadísticas a propósito del día mundial contra el cáncer,” 2025. [Online]. Available: <https://www.inegi.org.mx/contenidos/saladeprensa/aproposito/2025/EAPDMvsCancer25.pdf>
- [12] A. Ray, D. Madan, S. Patil, P. Pati, M. Rapsomaniki, A. Kohlakala, T. R. Dlamini, S. Muller, K. Rhrissorakrai, F. Utro, and L. Parida, “Hybrid quantum-classical graph neural networks for tumor classification in digital pathology,” in *QCE 2024*, 2024, Último acceso: 5 de marzo de 2025. [Online]. Available: <https://ieeexplore.ieee.org/document/10821390>
- [13] W. E. Maouaki, T. Said, and M. Bennai, “Quantum support vector machine for prostate cancer detection: A performance analysis,” *arXiv, Preprint 2403.07856*, 2024, Último acceso: 5 de

marzo de 2025. [Online]. Available: <https://arxiv.org/html/2403.07856v1#:~:text=This%20study%20addresses%20the%20urgent,aligns%20seamlessly%20with%20the%20unique>

- [14] J. Cheng, “Brain tumor dataset,” <https://doi.org/10.6084/m9.figshare.1512427.v5>, 2017, figshare. Dataset.
- [15] M. N. A. Mansoor A. Khan and B. Sikdar, “Beyond bits: A review of quantum embedding techniques for efficient information processing,” *IEEE Access*, vol. 12, 2024. [Online]. Available: [https://www.researchgate.net/publication/379221353\\_Beyond\\_Bits\\_A\\_Review\\_of\\_Quantum\\_Embedding\\_Techniques\\_for\\_Efficient\\_Information\\_Processing](https://www.researchgate.net/publication/379221353_Beyond_Bits_A_Review_of_Quantum_Embedding_Techniques_for_Efficient_Information_Processing)

## 7. Alumnos y Directores

**CARÁCTER:** Confidencial  
**FUNDAMENTO LEGAL:** Artículo 11 Fracc. V y Artículos 108, 113 y 117 de la Ley Federal de Transparencia y Acceso a la Información Pública.  
**PARTES CONFIDENCIALES:** Número de boleta y teléfono.

Diego Castillo Reyes.- Alumno de la carrera de Ing. en Inteligencia Artificial en ESCOM, Boleta: 2022630740, Tel. 5526595213, email: dcastillor1800@alumno.ipn.mx.

Firma:  \_\_\_\_\_


Marthon Leobardo Yañez Martínez.- Alumno de la carrera de Ing. en Inteligencia Artificial en ESCOM, Boleta: 2022630739, Tel. 5554678033, email: myanezm1800@alumno.ipn.mx.

Firma:  \_\_\_\_\_

Eduardo Muñoz González.- Alumno de la carrera de Ing. en Inteligencia Artificial en ESCOM, Boleta: 202302250, Tel. 5519614813, email: emunozg1901@alumno.ipn.mx.

Firma:  \_\_\_\_\_

Guerrero Estrada Areli Yesareth.- Candidata a Dra. en Ciencias de la Computación del CIC-IPN, M en T del CIDETEC-IPN en 2022, IC de la FES Aragon-UNAM en 2019, Q de la FQ-UNAM en 2013, Áreas de interés: Aprendizaje Automático, Computación Cuántica. Laboratorio de Ciencias de la Información Cuántica, CIC, Número de Cédula Profesional: 13575116 Tel. 5548592708, email: aguerreroe2022@cic.ipn.mx

Firma:  \_\_\_\_\_

Sánchez Manilla Angeles Alejandra.- Dra. En Ciencias de la Computación del CIC-IPN en 2022, M en T del CIDETEC-IPN en 2018, ISC de la ESCOM en 2009, Áreas de interés: Aprendizaje Automático, Computación Cuántica. Departamento de Ciencias e Ingeniería de la Computación, ESCOM, Tel. 5729600 Ext.52022, email: aasanchezm@ipn.mx

Firma:  \_\_\_\_\_